UTS

PEMBELAJARAN MESIN



NAMA : Bagas Satya Aninditha

NIM : 202431135

KELAS : F

DOSEN : Dr. Dra. Dwina Kuswardani, M.Kom

NO.PC : 8

ASISTEN : 1. Jonathan Juan Setyanto

2. Muhammad Caisar Gemilang Pratama

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

Contents

DAFTAR ISI 2
BAB I 3
PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II 5
LANDASAN TEORI 5
2.1 Domain Data dan Karakteristik Dataset Counter-Strike 2 5
2.2 Data Preprocessing dan Feature Scaling 5
2.2.1 Label Encoding 5
2.2.2 Feature Scaling (StandardScaler) 5
2.3 Algoritma K-Nearest Neighbors (KNN) 6
2.4 Algoritma Naive Bayes (Gaussian Naive Bayes) 6
2.5 Metrik Evaluasi Pemodelan Klasifikasi 7
BAB III 8
HASIL 8
BAB IV 11
PENUTUP 11
DAFTAR PUSTAKA 12

BAB I
PENDAHULUAN

1.1 Rumusan Masalah

Berdasarkan hasil praktikum UTS Pembelajaran Mesin yang telah dilakukan menggunakan dataset Counter-Strike 2, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana alur pemrosesan awal (*preprocessing data*) yang meliputi pengkodean label (*label encoding*) dan penyesuaian skala fitur (*feature scaling*) dilakukan pada dataset Counter-Strike 2?
2. Bagaimana kinerja dan akurasi algoritma K-Nearest Neighbors (KNN) dalam memprediksi pemenang ronde (*round winner*) pada game Counter-Strike 2?
3. Bagaimana kinerja dan akurasi algoritma Naive Bayes (Gaussian NB) dalam memprediksi pemenang ronde (*round winner*) pada game Counter-Strike 2?
4. Manakah algoritma yang memberikan performa akurasi dan klasifikasi lebih baik antara K-Nearest Neighbors (KNN) dan Naive Bayes berdasarkan evaluasi *confusion matrix* dan metrik klasifikasi?

1.2 Tujuan Masalah

Tujuan dan hasil yang diperoleh dari pelaksanaan praktikum UTS ini adalah:

1. Menerapkan tahapan *Exploratory Data Analysis* (EDA) serta pemrosesan data menggunakan *LabelEncoder* dan *StandardScaler* pada dataset Counter-Strike 2.
2. Membangun dan menguji model klasifikasi K-Nearest Neighbors (KNN) dengan $K = 5$ hingga memperoleh tingkat akurasi sebesar 83.25%.
3. Membangun dan menguji model klasifikasi Gaussian Naive Bayes hingga memperoleh tingkat akurasi sebesar 72.50%.
4. Mengidentifikasi perbandingan performa kedua algoritma dan menganalisis penyebab perbedaan akurasi berdasarkan karakteristik keterkaitan antar-fitur dalam dataset.

1.3 Manfaat Masalah

Manfaat yang diperoleh dari hasil praktikum UTS ini adalah:

1. **Manfaat Praktis:** Memahami implementasi langsung dari algoritma K-Nearest Neighbors dan Naive Bayes menggunakan bahasa pemrosesan Python dan library *Scikit-Learn* pada kasus dunia nyata (data e-sports).
2. **Manfaat Analitis:** Mampu mengevaluasi dan membandingkan kelebihan serta kekurangan antar-algoritma klasifikasi melalui metrik evaluasi *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *Confusion Matrix*.

3. **Manfaat Domestik/Domain:** Memberikan wawasan mengenai pentingnya faktor-faktor ekonomi dan kondisi fisik tim (seperti sisa darah, perisai, dan sisa uang) dalam menentukan peluang kemenangan ronde pada permainan Counter-Strike 2.

BAB II
LANDASAN TEORI

2.1 Domain Data dan Karakteristik Dataset Counter-Strike 2

Counter-Strike 2 merupakan permainan komputer bergenre *first-person shooter* berbasis taktis yang mempertemukan dua tim, yaitu Counter-Terrorist dan Terrorist. Setiap pertandingan terbagi ke dalam beberapa ronde independen di mana keputusan kemenangan ronde dipengaruhi oleh kombinasi faktor strategis, kondisi fisik, dan dinamika ekonomi tim secara langsung. Dalam ranah *machine learning*, prediksi pemenang ronde dikategorikan sebagai permasalahan klasifikasi biner untuk menebak tim yang akan keluar sebagai pemenang berdasarkan data statistik ronde yang sedang berjalan.

Dataset yang digunakan memuat serangkaian atribut fitur yang mencerminkan kondisi riil permainan. Atribut sisa waktu ronde menggambarkan tingkat tekanan waktu yang dihadapi oleh tim Terrorist dalam menyelesaikan objektif penanaman bom. Variabel skor perolehan dari masing-masing tim mencerminkan momentum dan kondisi psikologis permainan. Nama peta arena permainan memberikan konteks taktis karena setiap peta memiliki struktur tata letak yang memberikan tingkat kesulitan berbeda bagi kedua tim. Status penanaman bom menjadi penentu peralihan fokus strategi dari pertempuran terbuka menjadi pertahanan atau penjinakan bom. Selain itu, akumulasi sisa kesehatan dan poin perisai menggambarkan kekuatan tempur langsung, sedangkan total sisa modal uang dan kepemilikan helm menentukan kapasitas pasokan senjata utama serta daya tahan anggota tim dari serangan lawan. Seluruh indikator ini bermuara pada variabel target yang menandakan tim pemenang pada ronde tersebut.

2.2 Data Preprocessing dan Feature Scaling

2.2.1 Label Encoding

Sebagian besar algoritma pemodelan komputer membutuhkan masukan bertipe numerik agar dapat melakukan perhitungan operasional secara optimal. *Label Encoding* merupakan teknik pemrosesan awal data yang berfungsi mentransformasikan atribut bernilai kategorikal berbentuk teks maupun nilai logika boolean menjadi deret angka diskrit. Dalam konteks data permainan ini, variabel seperti nama peta dan variabel target pemenang ronde dipetakan ke dalam representasi angka sederhana sehingga siap diproses oleh algoritma pembelajaran mesin tanpa mengubah makna informasi asli dari data tersebut.

2.2.2 Feature Scaling (StandardScaler)

Atribut numerik dalam data permainan game umumnya memiliki rentang nilai yang bervariasi sangat tajam. Sebagai gambaran, fitur modal uang tim dapat mencapai angka belasan ribu, sementara jumlah kepemilikan helm hanya berada pada kisaran angka tunggal. Tanpa adanya penyesuaian skala, algoritma pemodelan yang bekerja

berbasis perhitungan jarak antar data akan menganggap fitur dengan rentang nilai besar memiliki bobot yang jauh lebih dominan dibanding fitur lainnya secara tidak seimbang. Melalui teknik standardisasi, seluruh fitur numerik ditransformasikan sehingga memiliki sebaran nilai dengan rata-rata nol dan varians satu. Hal ini memastikan setiap atribut memberikan kontribusi yang setara dalam proses analisis dan pelatihan model.

2.3 Algoritma K-Nearest Neighbors (KNN)

K-Nearest Neighbors merupakan salah satu algoritma pembelajaran mesin terawasi yang digunakan untuk menyelesaikan permasalahan klasifikasi. Algoritma ini bekerja tanpa membuat asumsi eksplisit mengenai bentuk distribusi awal data. Prinsip dasar dari algoritma ini adalah menentukan kelas label dari suatu data baru berdasarkan kemiripan lokasi atau jarak kedekatan terhadap kumpulan data latih yang sudah ada.

Proses klasifikasi dimulai dengan menentukan jumlah tetangga terdekat yang akan dijadikan acuan pengambilan keputusan. Selanjutnya, algoritma menghitung jarak antara titik data baru dengan seluruh data latih dalam ruang dimensi fitur. Setelah seluruh jarak terhitung, algoritma akan mengurutkan dan memilih sekumpulan tetangga terdekat sesuai dengan jumlah yang telah ditentukan. Kelas akhir dari data baru tersebut ditetapkan berdasarkan suara terbanyak dari kategori yang mendominasi di antara tetangga-tetangga terdekatnya. Keunggulan algoritma ini terletak pada kesederhanaannya serta kemampuannya mengelompokkan pola data dinamis yang memiliki keterkaitan erat antar atribut fiturnya.

2.4 Algoritma Naive Bayes (Gaussian Naive Bayes)

Naive Bayes merupakan algoritma klasifikasi probabilistik yang bekerja memanfaatkan konsep peluang dengan asumsi bahwa setiap atribut fitur bersifat independen atau saling bebas satu sama lain. Asumsi independensi ini mengartikan bahwa kehadiran suatu fitur dalam menentukan kelas tidak dipengaruhi oleh keberadaan fitur lainnya.

Dalam skenario data yang memiliki atribut numerik bernilai kontinu, pendekatan yang digunakan adalah Gaussian Naive Bayes, di mana sebaran peluang dari setiap variabel diasumsikan mengikuti pola distribusi normal. Algoritma ini menghitung peluang awal dari masing-masing kelas target serta peluang kemunculan kombinasi fitur pada setiap kelas tersebut. Hasil perkalian peluang-peluang tersebut akan menghasilkan nilai peluang posterior, di mana data baru akan diklasifikasikan ke dalam kelas yang memiliki nilai peluang tertinggi. Keunggulan utama dari Naive Bayes adalah kecepatan pemrosesan komputasinya yang sangat tinggi serta efisiensinya saat menangani data dengan banyak atribut variabel.

2.5 Metrik Evaluasi Pemodelan Klasifikasi

Untuk mengukur tingkat keberhasilan dan keakuratan model dalam memprediksi kelas target, digunakan matriks evaluasi klasifikasi yang membandingkan hasil prediksi model dengan data aktual. Matriks ini menghasilkan empat indikator utama, yaitu data positif yang diprediksi benar, data negatif yang diprediksi benar, data negatif yang salah diprediksi sebagai positif, serta data positif yang salah diprediksi sebagai negatif.

Berdasarkan keempat indikator tersebut, dihitung beberapa ukuran kinerja pemodelan. Akurasi mengukur proporsi total prediksi yang tepat terhadap keseluruhan sampel data uji. Presisi mengukur tingkat ketepatan model dalam menghasilkan prediksi kelas positif agar tidak terjadi kesalahan prediksi positif yang salah. Sensitivitas atau *recall* mengukur kemampuan model dalam menemukan kembali seluruh sampel kelas positif aktual yang ada. Sementara itu, nilai persentase *F1-score* memberikan gambaran keseimbangan antara presisi dan sensitivitas, yang sangat berguna untuk menilai performa model secara menyeluruh pada sebaran data yang dinamis.

BAB III

HASIL

1. Import Library

   Pada langkah pertama, dilakukan pengambilan (*import*) library dasar Python yang dibutuhkan dalam pengerjaan machine learning. Library pandas digunakan untuk mengolah data dalam bentuk tabel (*dataframe*), numpy untuk pemrosesan larik numerik, serta matplotlib.pyplot dan seaborn untuk menyajikan grafik visualisasi. Selain itu, dari modul sklearn diambil beberapa fungsi spesifik seperti train_test_split untuk membagi dataset, LabelEncoder dan StandardScaler untuk pra-pemrosesan data, algoritma KNeighborsClassifier dan GaussianNB sebagai model klasifikasi, serta metrik evaluasi seperti accuracy_score, classification_report, dan confusion_matrix.

```
[1]: # NIM: 202431135 - BAGAS SATYA ANINDITHA
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.neighbors import KNeighborsClassifier
from sklearn.naive_bayes import GaussianNB
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

print("Library berhasil di-import!")
```

```
Library berhasil di-import!
```

2. Load Dataset & Cek Informasi Data

   Pada langkah kedua, file dataset 03_counter_strike_2.csv dibaca ke dalam program menggunakan perintah pd.read_csv. Melalui keluaran df.head(), dapat dilihat gambaran 5 baris pertama data yang memuat fitur-fitur kondisi pertandingan Counter-Strike 2 seperti sisa waktu, skor kedua tim, nama peta, status bom, akumulasi darah, perisai, modal uang, helm, serta pemenang ronde. Selanjutnya, eksekusi df.info() mengonfirmasi bahwa terdapat total 2.000 baris data observasi dengan 14 atribut kolom. Hasil pengecekan df.isnull().sum() menunjukkan nilai 0 pada seluruh variabel, yang menandakan bahwa dataset dalam kondisi bersih tanpa ada data yang hilang (*missing values*) sehingga data siap untuk diproses ke tahap selanjutnya.

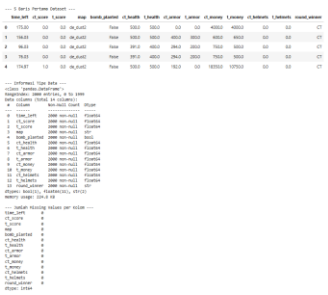
```
[2]: # NIM: 202431135 - BAGAS SATYA ANINDITHA
# Load file dataset counter strike 2
df = pd.read_csv('03_counter_strike_2.csv')

# Tampilkan 5 baris pertama
print("--- 5 Baris Pertama Dataset ---")
display(df.head())

# Cek struktur kolom dan tipe data
print("\n--- Informasi Tipe Data ---")
df.info()

# Cek apakah ada data yang kosong (null/missing values)
print("\n--- Jumlah Missing Values per Kolom ---")
print(df.isnull().sum())
```

```
--- 5 Baris Pertama Dataset ---
```



3. Preprocessing Data & Scaling

   Pada langkah ketiga, dilakukan pemrosesan awal terhadap dataset. Fitur bertipe teks seperti map dan target round_winner diubah menjadi deret angka menggunakan LabelEncoder, sementara variabel biner bomb_planted dikonversi ke format angka integer. Variabel target round_winner dipisahkan ke dalam variabel y, sedangkan 13 fitur penentu disimpan dalam matriks X. Data kemudian dibagi menggunakan train_test_split dengan proporsi 80% data latih (1.600 data) dan 20% data uji (400 data). Terakhir, fitur numerik diubah skalanya menggunakan StandardScaler agar seluruh fitur memiliki rerata nol dan standar deviasi satu. Penyelarasan skala ini sangat penting agar variabel dengan nilai nominal besar (seperti modal uang) tidak mendominasi perhitungan jarak pada algoritma K-Nearest Neighbors.

[3]:
```
# NIM: 202431135 - BAGAS SATYA ANINDITHA
# Encoding fitur kategorikal & boolean
le = LabelEncoder()
df_processed = df.copy()

df_processed['map'] = le.fit_transform(df_processed['map'])
df_processed['bomb_planted'] = df_processed['bomb_planted'].astype(int)
df_processed['round_winner'] = le.fit_transform(df_processed['round_winner']) # CT/T menjadi 0/1

# Pemisahan Fitur (X) dan Target (y)
X = df_processed.drop(columns=['round_winner'])
y = df_processed['round_winner']

# Split Data (80% Train, 20% Test)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Feature Scaling (Wajib untuk KNN)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print("Data Preprocessing selesai! Data siap dilatih.")
```

```
Data Preprocessing selesai! Data siap dilatih.
```

4. Pelatihan & Evaluasi Model K-Nearest Neighbors (KNN)

   Pada langkah keempat, dibangun model K-Nearest Neighbors (KNN) dengan menetapkan jumlah tetangga terdekat $K = 5$. Model dilatih menggunakan data latih yang telah diselaraskan skalanya (X_train_scaled), lalu diuji untuk memprediksi 400 data uji (X_test_scaled). Berdasarkan hasil klasifikasi, model KNN berhasil mencatatkan tingkat akurasi sebesar **83.25%** (berhasil memprediksi 333 data dengan benar dari 400 sampel). Pada rincian laporan klasifikasi, kelas Counter-Terrorist (CT) memperoleh presisi 0.78 dan recall 0.79, sedangkan kelas Terrorist (T) memperoleh presisi 0.87 dan recall 0.86, dengan rerata tertimbang (*weighted average*) F1-score sebesar 0.83.

[6]:
```
# NIM: 202431135 - BAGAS SATYA ANINDITHA
# Inisialisasi dan Latih Model KNN (K=5)
knn_model = KNeighborsClassifier(n_neighbors=5)
knn_model.fit(X_train_scaled, y_train)

# Prediksi
y_pred_knn = knn_model.predict(X_test_scaled)

# Evaluasi KNN
acc_knn = accuracy_score(y_test, y_pred_knn)
print(f"--- EVALUASI K-NEAREST NEIGHBORS (KNN) ---")
print(f"Akurasi KNN: {acc_knn * 100:.2f}%\n")
print("Classification Report:")
print(classification_report(y_test, y_pred_knn))
```

```
--- EVALUASI K-NEAREST NEIGHBORS (KNN) ---
Akurasi KNN: 83.25%

Classification Report:
              precision    recall  f1-score   support

           0       0.78      0.79      0.79       156
           1       0.87      0.86      0.86       244

    accuracy                           0.83       400
   macro avg       0.82      0.83      0.82       400
weighted avg       0.83      0.83      0.83       400
```

5. Pelatihan & Evaluasi Model Naive Bayes (Gaussian NB)

Pada langkah kelima, dilakukan pelatihan model Gaussian Naive Bayes pada dataset yang sama untuk melihat performa pemodelan berbasis probabilistik. Hasil pengujian terhadap 400 data uji menunjukkan bahwa model Naive Bayes memperoleh tingkat akurasi sebesar **72.50%** (berhasil memprediksi 290 data dengan benar). Untuk kelas CT, diperoleh presisi 0.63 dan recall 0.71, sementara untuk kelas T diperoleh presisi 0.80 dan recall 0.73. Secara keseluruhan, rerata tertimbang F1-score dari model Naive Bayes berada pada angka 0.73, yang berada di bawah pencapaian algoritma KNN.

[8]:
```
# NIM: 202431135 - BAGAS SATYA ANINDITHA
# Inisialisasi dan Latih Model Naive Bayes
nb_model = GaussianNB()
nb_model.fit(X_train_scaled, y_train)

# Prediksi
y_pred_nb = nb_model.predict(X_test_scaled)

# Evaluasi Naive Bayes
acc_nb = accuracy_score(y_test, y_pred_nb)
print(f"--- EVALUASI NAIVE BAYES (GAUSSIAN NB) ---")
print(f"Akurasi Naive Bayes: {acc_nb * 100:.2f}%\n")
print("Classification Report:")
print(classification_report(y_test, y_pred_nb))
```

```
--- EVALUASI NAIVE BAYES (GAUSSIAN NB) ---
Akurasi Naive Bayes: 72.50%

Classification Report:
              precision    recall  f1-score   support

           0       0.63      0.71      0.67       156
           1       0.80      0.73      0.76       244

    accuracy                           0.72       400
   macro avg       0.71      0.72      0.72       400
weighted avg       0.73      0.72      0.73       400
```

6. Visualisasi Confusion Matrix & Grafik Perbandingan Akurasi
Pada langkah keenam, dilakukan pembuatan visualisasi matrik kebingungan (*Confusion Matrix*) dan grafik batang perbandingan akurasi menggunakan library matplotlib dan seaborn. Pada visualisasi Confusion Matrix KNN, tercatat model memprediksi 124 data True Negative (CT) dan 209 data True Positive (T) secara benar, dengan kesalahan 32 False Positive dan 35 False Negative. Sementara pada Naive Bayes, diprediksi 111 data True Negative dan 179 data True Positive secara benar, dengan kesalahan 45 False Positive dan 65 False Negative.

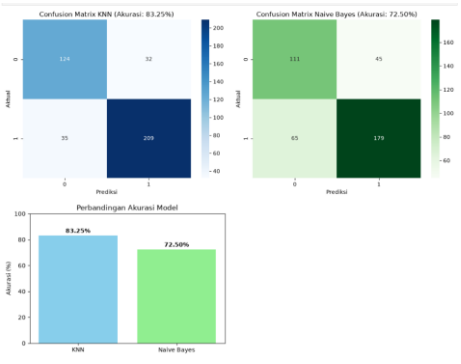
[9]:
```
# NIM: 202431135 - BAGAS SATYA ANINDITHA
fig, axes = plt.subplots(1, 2, figsize=(12, 5))

# Confusion Matrix KNN
sns.heatmap(confusion_matrix(y_test, y_pred_knn), annot=True, fmt='d', cmap='Blues', ax=axes[0])
axes[0].set_title(f'Confusion Matrix KNN (Akurasi: {acc_knn*100:.2f}%)')
axes[0].set_xlabel('Prediksi')
axes[0].set_ylabel('Aktual')

# Confusion Matrix Naive Bayes
sns.heatmap(confusion_matrix(y_test, y_pred_nb), annot=True, fmt='d', cmap='Greens', ax=axes[1])
axes[1].set_title(f'Confusion Matrix Naive Bayes (Akurasi: {acc_nb*100:.2f}%)')
axes[1].set_xlabel('Prediksi')
axes[1].set_ylabel('Aktual')

plt.tight_layout()
plt.show()

# Grafik Perbandingan Akurasi
plt.figure(figsize=(6, 4))
models = ['KNN', 'Naive Bayes']
accuracies = [acc_knn * 100, acc_nb * 100]
plt.bar(models, accuracies, color=['skyblue', 'lightgreen'])
plt.ylabel('Akurasi (%)')
plt.title('Perbandingan Akurasi Model')
plt.ylim(0, 100)
for i, v in enumerate(accuracies):
    plt.text(i, v + 2, f"{v:.2f}%", ha='center', fontweight='bold')
plt.show()
```



BAB IV

PENUTUP

Berdasarkan landasan teori dan seluruh rangkaian praktikum Machine Learning yang telah dilakukan pada dataset Counter-Strike 2 (03_counter_strike_2.csv), dapat ditarik beberapa kesimpulan utama:

1. **Tahapan Pemrosesan Data (Preprocessing):**

   Penggunaan LabelEncoder dan StandardScaler terbukti sangat krusial dalam menyelaraskan atribut data permainan. Standardisasi fitur numerik berhasil mencegah atribut ber-skala besar (seperti sisa uang modal tim) mendominasi perhitungan jarak pada algoritma K-Nearest Neighbors secara tidak seimbang.

2. **Kinerja Algoritma K-Nearest Neighbors (KNN):**

   Model K-Nearest Neighbors dengan konfigurasi $K = 5$berhasil memperoleh tingkat akurasi sebesar **83.25%** (memprediksi 333 data dengan benar dari total 400 data uji). Model ini mencatatkan nilai rerata tertimbang (weighted average) F1-score sebesar 0.83.

3. **Kinerja Algoritma Naive Bayes (Gaussian NB):**

   Model Gaussian Naive Bayes memperoleh tingkat akurasi sebesar **72.50%** (memprediksi 290 data dengan benar dari total 400 data uji), dengan rerata tertimbang F1-score sebesar 0.

4. **Perbandingan Komparatif Model:**

   Algoritma **K-Nearest Neighbors (KNN)** terbukti lebih unggul dibandingkan Naive Bayes dengan selisih akurasi mencapai **10.75%**. Hal ini disebabkan karena atribut fitur pada game Counter-Strike 2 (seperti sisa darah, poin perisai, status bom, dan modal uang) memiliki keterkaitan erat yang saling memengaruhi secara simultan. Asumsi independensi fitur pada Naive Bayes kurang sesuai untuk karakteristik data pertempuran yang dinamis ini, sedangkan KNN mampu mengukur kemiripan jarak dari seluruh atribut secara efektif.

DAFTAR PUSTAKA

1. Bramer, M. (2020). *Principles of Data Mining* (4th ed.). Springer.
2. Han, J., Kamber, M., & Pei, J. (2022). *Data Mining: Concepts and Techniques* (4th ed.). Morgan Kaufmann.
3. Hastie, T., Tibshirani, R., & Friedman, J. (2021). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
4. Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2021). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
5. Prasetyo, E. (2021). *Data Mining: Konsep dan Aplikasi Menggunakan MATLAB dan Python*. Andi Publisher.